SSAFY 16기 2회차 AI 챌린지

이미지로 묻고, AI로 답하다

텍스트 이미지 기반 VQA 솔루션

Final Public LB 0.96127

B062 파이브가이즈 | 김순하 · 김승훈 · 김지호 · 송석현 · 송현준

SAMPLE · VQA

사진 속 선반에 적힌 문구는 무엇인가요?

a **SUNDAY BURGER LOVE**

b MONDAY SALAD TIME

c FRIDAY PIZZA PARTY

d WEDNESDAY SOUP DAY

ANSWER **a**

세 대형 VLM의 확률을 합쳐 Public 0.96127

FINAL PUBLIC LB

0.96127

단일 모델 최고 0.96008 → +0.00119

가중 Soft Voting

Qwen3.8-27B	**0.40**
Gemma4-31B	**0.35**
Qwen3.5-27B	**0.25**

1 데이터

촬영 환경 증강 6종
원본당 변형 9개
Dev 합의 라벨 2,026
질문·이미지 단위 분할

68,242행

2 학습

Qwen3.8-27B BF16
Gemma4-31B QLoRA
Qwen3.5-27B
최대 896px 입력

LoRA r16 · 27~31B

3 추론·앙상블

a/b/c/d 토큰 확률
가중 평균
0.40 : 0.35 : 0.25
확률 CSV로 재현

Public 0.96127



핵심 관찰

Qwen3.8-27B는 학습 전(zero-shot)에도 검증 94.37%. 미세조정이 약 +1%p, 서로 다른 계열의 확률 앙상블이 마지막 +0.1%p를 만들었다.

과제: 이미지 속 글자를 읽고 4지선다로 답하기

입력
이미지 + 질문
+ 선택지 a~d

→

모델
VQA (VLM)

→

출력
정답 1글자

평가 지표 Accuracy

무작위 기준 25%

증강은 train·dev에만 허용

학습 데이터 예시 · train_0001

사진 속 선반에 적힌 문구는 무엇인가요?

- **a SUNDAY BURGER LOVE**
- b MONDAY SALAD TIME
- c FRIDAY PIZZA PARTY
- d WEDNESDAY SOUP DAY

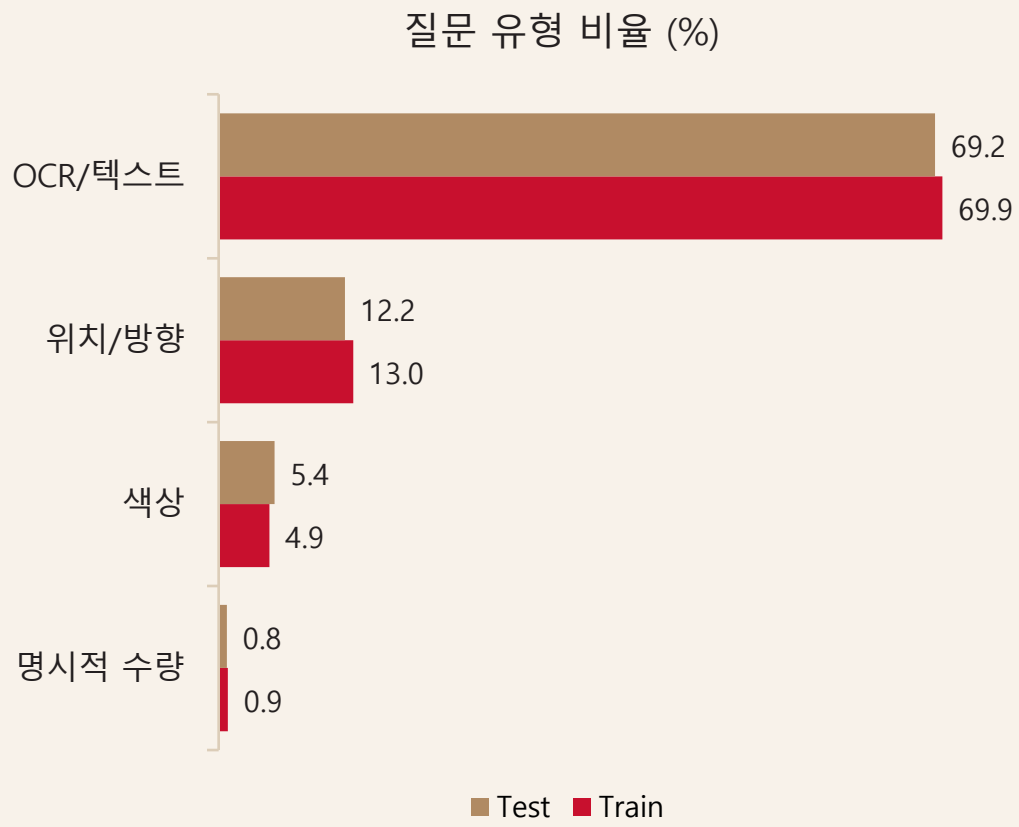
정답 a

train
학습용 · 정답 있음
6,714

test
제출 대상 · 정답 없음
6,714

dev
정답 대신 교육생 응답 1~5
2,683

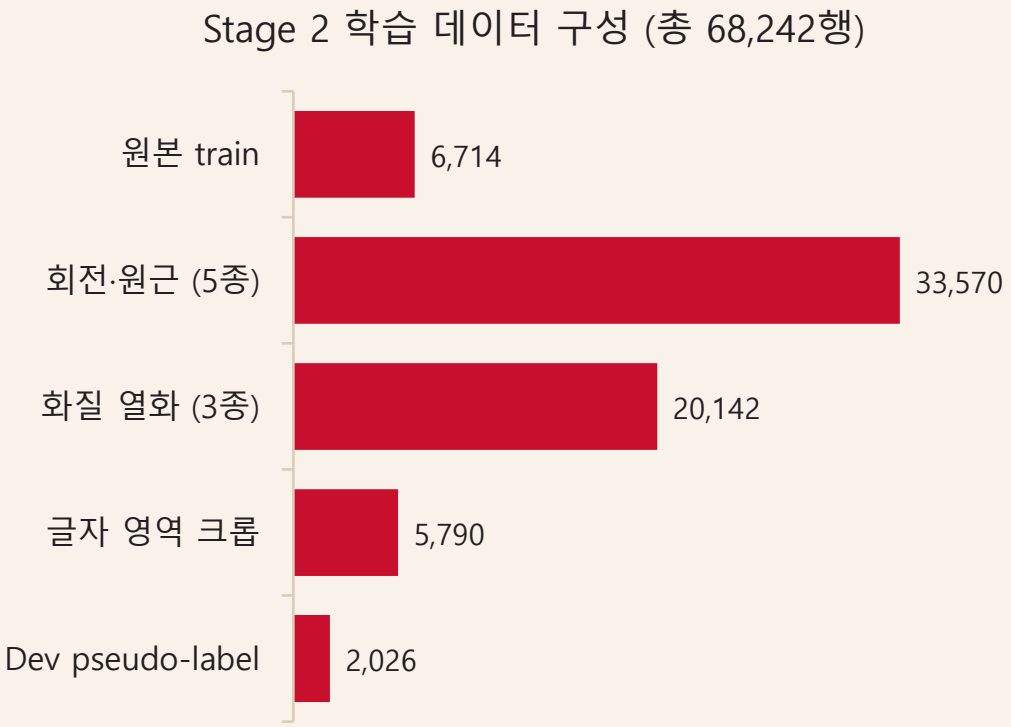
EDA: 70%가 글자 읽기 문제, 병목은 해상도



질문 키워드 기반 휴리스틱 분류(팀 EDA) · 한 질문이 여러 유형에 중복 포함될 수 있음

발견	결정
OCR/텍스트 질문 약 70%	→ 대형 VLM + OCR 프롬프트
질문 31.8자 · 선택지 8.9자 이미지 짧은 변 약 720px	→ 최대 896px 고해상도 입력
같은 질문 문장 반복 (최다 62회)	→ 질문 문장 단위 Group split
정답 a~d 비율 24.5~25.6%	→ 정답 층화 분할
dev 최다 3표 이하, 동률 465건	→ 3표 합의 2,026문항만

데이터: 촬영 환경을 흉내 낸 증강과 Dev 합의 라벨



기하 변환

회전 ±5°·±10° · 원근 변환

기울어진 촬영 각도

화질 열화

저해상도 · 가우시안 블러 · JPEG

흔들림 · 저화질 · 압축

글자 영역 크롭

EasyOCR 검출 영역 + 여백 30%

멀리서 찍힌 작은 글자 확대

Dev pseudo-label

교육생 5명 중 3명 이상 같은 답

2,683문항 중 2,026문항 사용

누수 방지: 먼저 나누고 train만 증강 · 중첩 증강 없음

외부 데이터 5종 8,292문항은 Stage 3용 · 최종 앙상블엔 미반영
ST-VQA · CLEVR · RCTW-17 · JaWildText · COCO-Text

파이프라인: 세 갈래로 학습하고, 확률로 합친다

데이터

- train 6,714
- 증강 변형 59,502
- Dev 합의 라벨 2,026

외부 데이터 8,292
Stage 3용 · 최종 모델 미반영

Qwen3.8-27B

단일 0.95829

BF16 LoRA r16 · 최대 896px
Random-View 증강 80% · 1,510 step

→ p(a,b,c,d) × 0.40

Gemma4-31B

단일 0.96008

NF4 QLoRA r16 · 최대 672px
커리큘럼 Stage 1 → Stage 2 (43%)

→ p(a,b,c,d) × 0.35

Qwen3.5-27B

단일 0.94489

NF4 · 최대 672px
LoRA 2 update → 사실상 zero-shot

→ p(a,b,c,d) × 0.25

가중 Soft Voting

Public
0.96127

모델 ① Qwen3.8-27B: 양자화 없이 BF16 LoRA

해상도 자동 선택

896→576px 후보를 최악 조건(최장 질문 + 최대 해상도)으로 시험, 예상 peak 88GB 이하의 최대값 → 896px

Gated DeltaNet까지 LoRA

attention · MLP · DeltaNet projection 496개 모듈, 1.17억 파라미터(0.42%) 학습, vision tower는 동결

Random-View 증강

매 epoch 원본마다 원본 또는 9개 변형 중 1장. 변형 확률 80%, epoch 길이가 그대로라 학습 시간 증가 없음

규칙으로 고르고 전체 재학습

후보가 +2문항 이상일 때만 채택 → LoRA 재초기화 후 train 6,714장 전체를 1,510 step 학습

항목	최초 27B 시도	최종
학습률	1e-4	**2e-5**
LoRA rank	8	**16**
Effective batch	2	**8**
LoRA 대상	기본	**+ DeltaNet**
최대 epoch	5	**2**
입력 해상도	384px	**최대 896px**

최초 설정은 팀 발표 자료 기준 · 여러 항목을 함께 바꿔 항목별 기여도는 측정하지 않음

94.37%
학습 전 검증

95.41%
증강 80% 검증

0.95918
Public (분할 학습)

모델 ② 3-Stage 커리큘럼: 하나의 LoRA를 이어서 학습

Stage 1 기본 train

6,714행 · 과제 형식 적응

→

Stage 2 증강 + Dev 합의 라벨

68,242행 · 촬영 환경 강건성

→

Stage 3 외부 데이터 5종

8,292행 · 다국어 · 색상 · 개수

NF4 4-bit QLoRA | LoRA r16 | 256²~672² px | PagedAdamW8bit | 100 update마다 재개 체크포인트

모델	앙상블 시점 학습 상태	Stage별 검증	Public
Gemma4-31B	Stage 2의 43% (3,485 / 8,104 update)	97.66% (S1)	**0.96008**
Qwen3.5-27B	update 2회 → 사실상 zero-shot	—	**0.94489**
Qwen3.5-4B	3 Stage 완주	91.8 / 89.5 / 93.8%	**0.85224**
Gemma4-E2B	3 Stage 완주	84.8 / 71.9 / 85.5%	**0.64462**

분홍색 행: 최종 앙상블에 들어간 모델 · Stage별 검증은 각 Stage 데이터에서 256문항 생성 평가

관찰

모델 용량이 결정적
Stage 2를 43%만 학습한 31B가 3 Stage를 완주한 4B보다 Public +0.108

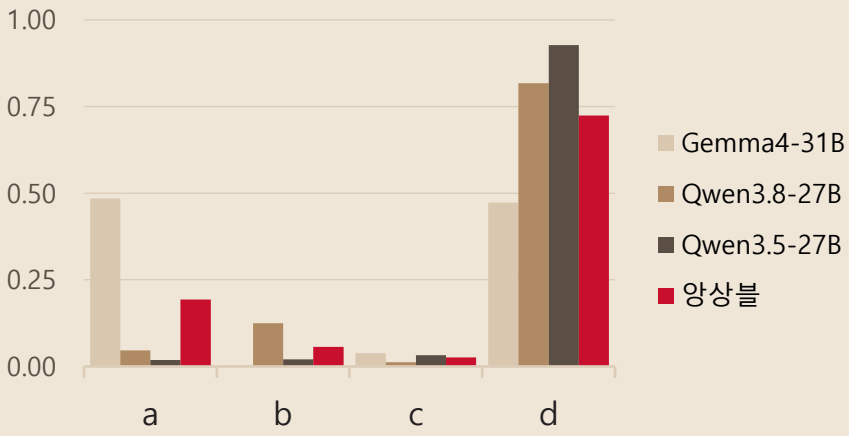
Stage 검증 ≠ test
소형 모델은 검증 85~94%인데 Public 0.64~0.85

추론: 생성 대신 a·b·c·d 네 토큰의 확률을 읽는다

이미지 + 질문 + 보기 a~d → **VLM + LoRA** → 다음 토큰 logit → a·b·c·d 4개만 선택 → 4-way softmax → **p_a~p_d + margin**

예시 · test_0003

IT대학 발전기금 현황판에서 50주년 후원금 중 10억원 이상을 기부한 기업은? (a) SK hynix (b) LG (c) 삼성전자 (d) 세 가지 모두



Gemma4-31B는 a와 d 사이에서 망설였지만
(0.485 : 0.473) 두 Qwen이 d에 확신
→ **앙상블 d (0.724)**

형식 오류 0
항상 a~d 중 하나를 고른다

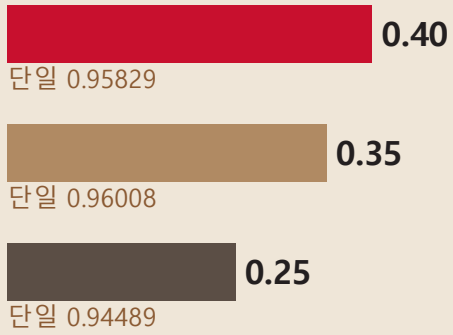
생성 결과와 일치 확인
학습 전 모델에서 greedy 생성과 64/64 일치

문항당 0.29초
Qwen3.8-27B, test 6,714문항 34분

앙상블 입력
확률과 margin을 CSV로 저장

앙상블: 계열이 다른 모델이 서로의 오답을 덮는다

가중치




```
p = 0.40·p_Qwen3.8 + 0.35·p_Gemma +
0.25·p_Qwen3.5 → argmax
```

단일 최고 0.96008 → **0.96127**

test 6,714문항 예측 일치도



세 모델 일치	6,162
두 모델만 일치	511
모두 다름	41

391

Qwen3.8과 Gemma가 갈린 문항 (5.8%)

252 : 134 : 5

그 문항의 최종 답
Qwen3.8 쪽 : Gemma 쪽 : 제3 보기

9가지

다른 결합 방식 비교 (temperature, 다수결, 게이팅 등)
→ top3와 31~72문항 차이, top3 유지

실험 설계: 작게 비교하고, 크게 확장하고, 규칙으로 고른다

작게 비교 → 크게 확장

Qwen2.5-VL-7B와 Qwen3-VL-8B를 약 1,700장으로 비교해 방향을 정한 뒤 96GB GPU에서 27B로 확장

누수 없는 검증

질문 문장 단위(Qwen3.8), 이미지 단위(커리큘럼) Group split. 증강은 train 분할에서 파생된 것만 쓰도록 assert

검증 ≠ 제출

675문항에서 2문항 = 0.3%p. "+2문항 이상일 때만 채택" 규칙을 코드로 고정해 감으로 고르지 않음

다양성과 재현성

Qwen·Gemma 두 계열을 학습하고 모든 모델의 a/b/c/d 확률을 저장해 나중에 조합

진행 단계

탐색
7B vs 8B, 프롬프트 비교 (A100)

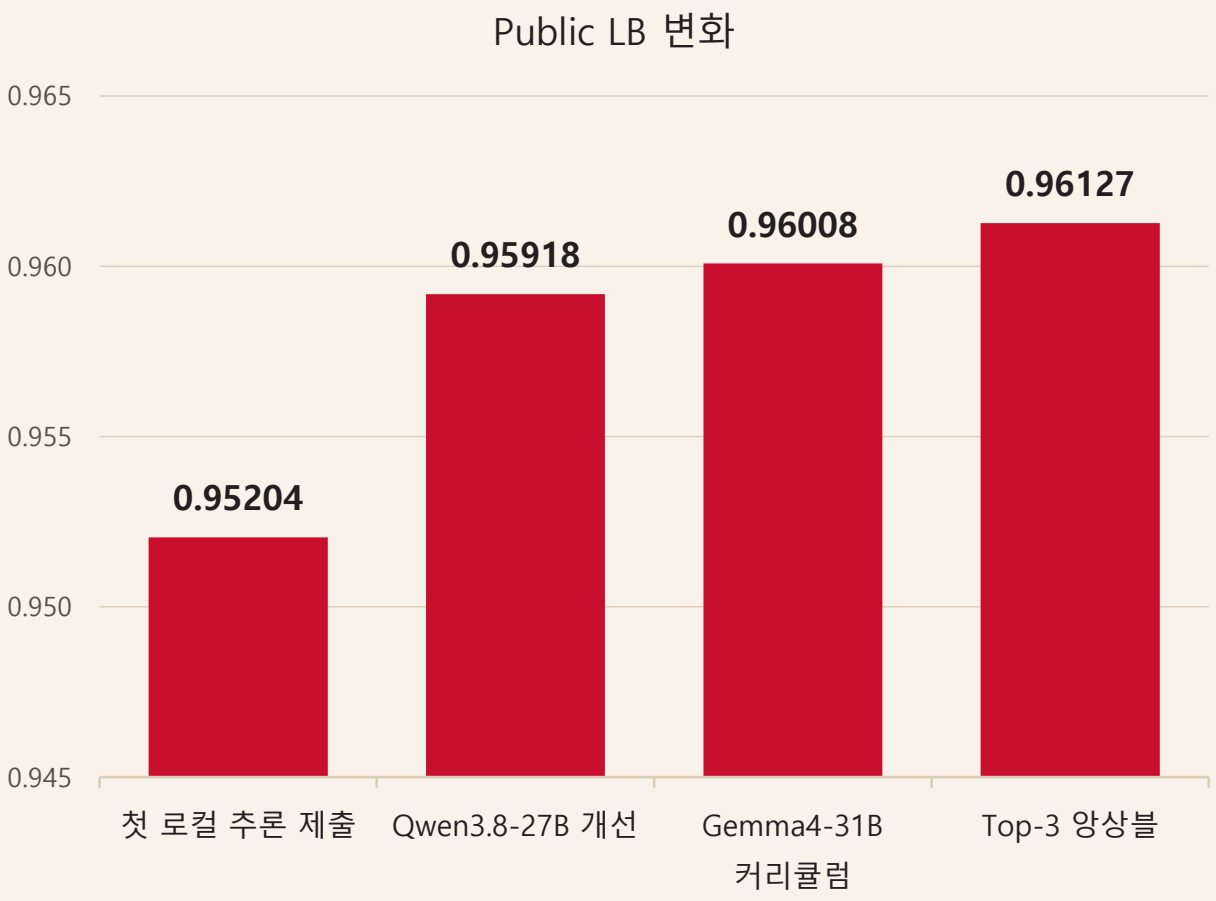
확장
27B BF16 첫 학습 → 과적합 신호

개선
일반화 설정 + 증강 → 0.95918

다양화
3-Stage 커리큘럼 4종 → Gemma 0.96008

결합
확률 Soft Voting → 0.96127

결과: 0.95204에서 0.96127까지

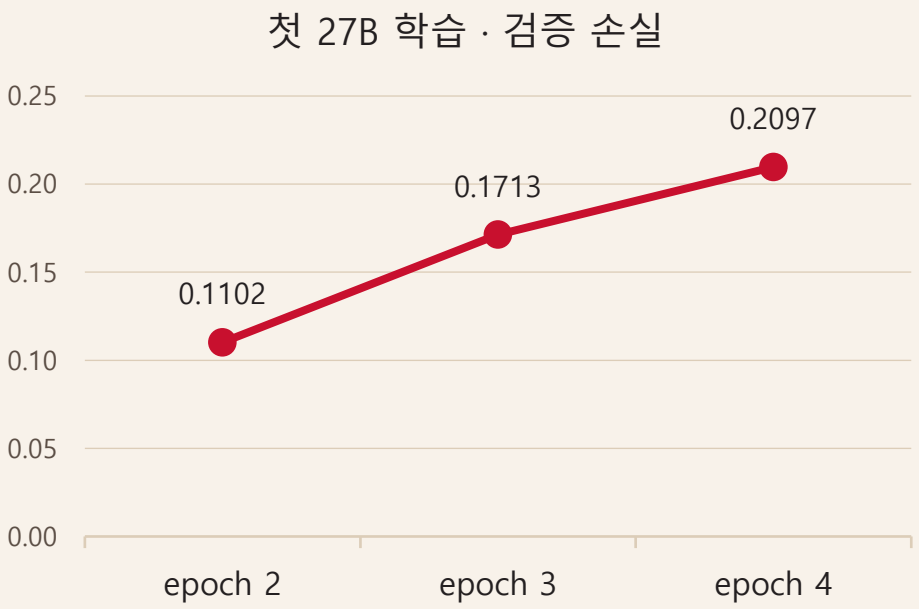


모델	설정	Public
Qwen3.8-27B	검증 분할 학습 (증강 70·80%)	0.95918
Qwen3.8-27B ★	전체 6,714장 재학습	0.95829
Gemma4-31B ★	Stage 1 + Stage 2 43%	0.96008
Qwen3.5-27B ★	사실상 zero-shot	0.94489
Qwen3.5-4B	3-Stage 완주	0.85224
Gemma4-E2B	3-Stage 완주	0.64462
Top-3 앙상블	★ 가중 평균 0.40 : 0.35 : 0.25	**0.96127**

★ 최종 앙상블 구성 모델 · 첫 로컬 추론 제출 점수는 팀 발표 자료(Day 2) 기준

Qwen3.8 재학습 모델은 단일 점수가 조금 낮았지만(−0.00089), 전체 데이터를 본 모델로 앙상블에 사용

시행착오: 멈추고, 원인을 보고, 방향을 바꿨다



+2문항의 착시
증강 80% 후보의 검증 +0.30%p는 675문항 중 2문항.
Public은 0.95918로 같았다.

1 오래 학습할수록 나빠졌다

epoch 2→3 검증 손실 +55%, 과적합

→ 학습률 1e-4→2e-5, epoch 5→2, batch 8

2 검증 상승 ≠ 제출 상승

+2문항은 노이즈 수준

→ 채택 규칙(+2문항 이상)을 코드로 고정

3 답만 합치는 LLM 심판

제출 CSV 3개의 불일치 286문항을 27B에게 재판정 — 정답 없이 효과 검증 불가

→ 미채택 → 체크포인트 확률 앙상블

4 전체 재학습이 −0.00089

검증셋 제거·LoRA 재초기화·샘플 순서가 동시에 바뀜

→ 다음에는 한 번에 한 조건만 변경

한계와 다음 단계

커리큘럼 완주

Gemma4-31B는 Stage 2의 43%, Qwen3.5-27B는 사실상 학습 없이 사용. 대형 모델로 세 Stage를 마쳤을 때의 효과는 미확인

외부 데이터 ablation

Stage 3 외부 데이터가 대형 모델의 test 성능을 올리는지 분리 검증 필요. 한 번에 한 조건만 변경

검증셋 기반 가중치

앙상블 가중치를 Public 점수에 기대어 정함. out-of-fold 확률로 가중치와 temperature 탐색

k-fold 검증

675문항 한 번의 분할에서는 2문항이 0.3%p. 교차검증으로 판단 신뢰도 개선

저확신 문항 TTA

앙상블 margin 0.2 미만 171문항에 여러 해상도·글자 영역 크롭 추론 적용

선택지 편향 점검

정답 선택지가 평균 1자 길다(9.68 vs 8.61자). 이미지 없이 선택지만 보는 기준선으로 점검

재현: 저장된 확률에서 최종 제출까지 한 줄

```
$ pip install pandas numpy
$ python scripts/ensemble_top3.py
저장: results/submissions/submission_top3_reproduced.csv (6,714행)
정답 분포: {'a': 1731, 'b': 1691, 'c': 1631, 'd': 1661}
기존 제출과 다른 답: 0개
```

실제 제출 파일과 바이트 단위 일치 · GPU 불필요

전체 재학습 순서

1. all_augmentation.ipynb — 증강 6종 + Dev 합의 라벨
2. build_augmentation_manifest.py → Qwen3.8-27B 노트북 (G4, 약 6.7시간)
3. 3-Stage 노트북 — Gemma4-31B · Qwen3.5-27B 확률 CSV
4. ensemble_top3.py — 세 확률을 가중 평균해 제출 파일 생성

저장소 구조

```
ssafy16-2-vqa-solution/
├── README.md
├── docs/  발표 자료
├── notebooks/
│   ├── 00_baseline/
│   ├── 01_data/          증강
│   ├── 02_qwen38_27b/    단일 모델
│   ├── 03_curriculum/    3-Stage
│   └── 04_ensemble/
├── scripts/  재현·변환 스크립트
├── data/     데이터 구성 문서
└── results/
    ├── probabilities/  5개 모델 확률
    ├── submissions/    최종 제출
    └── logs/           학습 기록
```

팀 파이브가이즈

기본 train 학습과 증강·데이터·앙상블 실험을 병행한 투트랙 방식

송석현 모델 학습
베이스 모델 비교, 27B LoRA 학습 설계

김승훈 프롬프트·실험 관리
OCR 특화 프롬프트, WandB 실험 기록, 앙상블 검토

김순하 데이터 증강·추가 데이터
외부 VQA 데이터 수집·정제, 색상·개수·영어 데이터

김지호 데이터 증강·모델 학습
촬영 환경 모사 증강 6종, Dev pseudo-label

송현준 추가 데이터 확보
외부 VQA 수집·정제, 한·중·일·비영어권 데이터

THANK YOU

Q&A

B062 파이브가이즈