SSAFY 16기 2회차 AI 챌린지

이미지로 묻고, AI로 답하다

텍스트 이미지 기반 VQA 모델 개발

B062_파이브가이즈 | 김순하, 김승훈, 김지호, 송석현, 송현준



ORDER · VQA

햄버거 사진의 프랜차이즈는 어디인가요?

a 롯데리아

b 버거킹

c **파이브가이즈**

d 맥도날드

ANSWER **C**

파이브가이즈



송석현

[모델 학습]

베이스 모델 비교,
27B LoRA 학습 설계



김승훈

[프롬프트 및 실험 관리]

OCR 특화 프롬프트,
WandB 실험 기록, 앙상블 검토



김순하

[데이터 증강 및 추가 데이터 확보]

외부 VQA 데이터 수집·정제
출처와 라벨 방식 검증
색상, 개수 데이터 확보
영어 데이터 확보



김지호

[데이터 증강 및 모델 학습]

촬영 환경 모사 증강 6종,
Dev pseudo-label



송현준

[추가 데이터 확보]

외부 VQA 데이터 수집·정제
한, 중, 일 언어 데이터 확보
비영어권 데이터 확보

투트랙 방식

기본 train 데이터로 모델 학습
WandB를 통해 학습 현황을 실시간 공유

증강 데이터 및 추가 데이터 확보
프롬프트, 앙상블 등 별도 테스트 병행

과제: 이미지 속 글자를 읽고 4지선다로 답하기

입력
이미지 + 질문
+ 선택지 a~d

→

모델
VQA (VLM)

→

출력
정답 1글자

평가 지표 Accuracy

무작위 baseline 25%

증강은 train·dev에만 허용

학습 데이터 예시 · train_0001

사진 속 선반에 적힌 문구는 무엇인가요?

a SUNDAY BURGER LOVE

b MONDAY SALAD TIME

c FRIDAY PIZZA PARTY

d WEDNESDAY SOUP DAY

정답 a

train

학습용 · 정답 있음

6,714

test

제출 대상 · 정답 없음

6,714

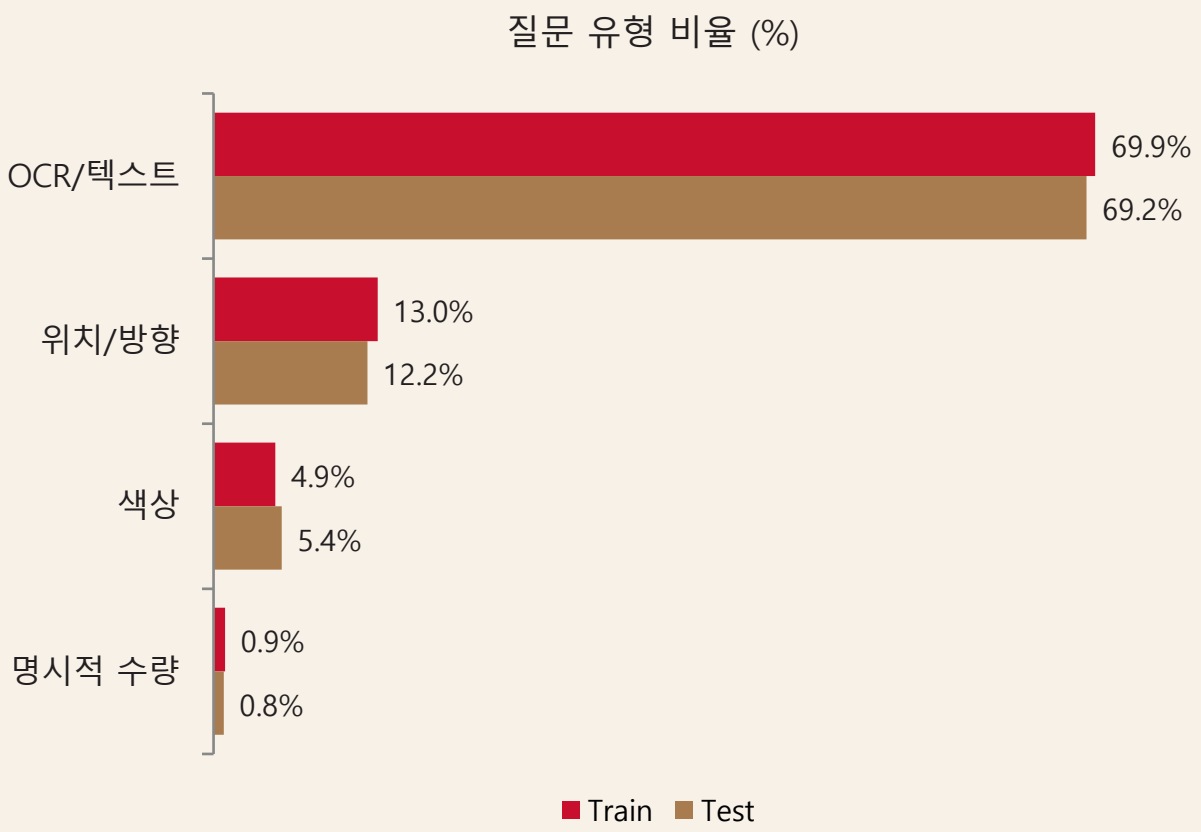
dev

정답 대신 교육생 응답 1~5

2,683

ID·이미지 경로 중복 0건
train/test 핵심 컬럼 결측 0건

EDA ① 문제의 약 70%가 글자를 읽어야 풀린다



질문 키워드 기반 1차 휴리스틱 분류 · 한 질문이 여러 유형에 중복 포함될 수 있음

가장 많이 반복된 질문 TOP 5 (train)

이 가게의 이름은 무엇인가요?	62회
이 건물의 이름은 무엇인가요?	33회
이 가게의 상호명은 무엇인가요?	29회
이 책의 제목은 무엇인가요?	29회
이 제품의 이름은 무엇인가요?	24회

Scene Text VQA 성격

간판·상품·책에서 글자를 찾아 읽는 능력이 병목. 같은 질문 문장도 이미지·선택지가 달라 문장 암기로는 풀 수 없다.

EDA ② 데이터가 알려준 접근 방향

발견	의미	우리의 결정
질문 평균 31.8자, 선택지 8.9자로 짧다	텍스트 길이보다 이미지 해상도·OCR 품질이 병목	고해상도 입력
OCR/텍스트 질문이 약 70%	글자 인식과 다국어 이해가 강한 모델이 유리	대형 VLM + OCR 프롬프트 해당 특성에 맞는 데이터 추가 확보
정답 a~d가 24.5~25.6%로 균등, Train·Test 통계가 유사	불균형 처리 불필요, 로컬 검증으로 리더보드 추정 가능	원본 단위 검증 분할
Dev 최다 득표가 3표 이하, 동률 465건	다수결을 정답처럼 쓰면 label noise 유입	3표 이상 선지만 보조 실험

참고: 정답 선택지가 오답보다 평균 약 1자 길다(9.68자 vs 8.61자). 선택지 편향 여부는 text-only baseline으로 확인할 예정

접근 ① 작게 비교하고, 크게 확장한다

1 소규모 모델 비교

- Qwen2.5-7B vs Qwen3-8B
- 약 1,700장 (학습 90% · 검증 10%)
- 동일 조건 · 2 epoch
- Colab A100 활용

2 프롬프트 비교

- Qwen2.5-7B · 약 1,000장
- 프롬프트만 바꿔 비교
- 정확도와 손실을 함께 확인
- Colab A100 활용

3 27B로 확장

- Colab G4 · RTX PRO 6000 (96GB)
- BF16으로 양자화 없이 학습
- Qwen3.8-27B + LoRA

판단 원칙

작은 검증셋에서는 1~2문항이 순위를 바꾼다.
방향만 정하고 우열은 단정하지 않았다.

왜 더 큰 모델인가

OCR·다국어 질문 비중이 높아 더 큰 VLM의 글자 인식·언어 이해 능력을 활용하기로 했다. 96GB GPU 확보로 실행이 가능해졌다.

접근 ② 작은 글자는 크게 보고, 답은 한 글자로

입력 해상도



- 원본 짧은 변 720px. 384로 줄이면 간판·가격표의 작은 글자가 뭉개진다.
- 96GB GPU로 더 많은 visual token을 감당할 수 있다.

프롬프트 설계 4원칙

1. **페르소나** 다국어 OCR(한·영·중·일)과 공간 추론 전문가
2. **단계적 분석** 글자 전사 → 층·방향·표 관계 → 선택지 대조
3. **애매할 때** 완벽히 맞지 않아도 가장 타당한 보기 하나 선택
4. **출력 강제** 소문자 a/b/c/d 한 글자, 설명 금지

```
SYSTEM_INSTRUCT = (
  "You are an expert Visual Question Answering system
   specialized in multilingual OCR (Korean, English, Chinese,
   Japanese) and complex spatial visual reasoning. ..."
  "4. Output ONLY one lower-case letter among a, b, c, or d."
```

접근 ③ 27B LoRA 학습 설계: 일반화 우선

항목	최초	개선	의도
학습률	1e-4	**2e-5**	과한 업데이트 억제
LoRA rank	8	**16**	적응 용량 확보
Effective batch	2	**8**	그래디언트 안정화
적용 모듈	기본	**+ DeltaNet projection**	모델 구조에 맞춤
최대 epoch	5	**2**	과적합 구간 회피
입력 해상도	기존	**확대**	작은 글씨 식별



여러 설정을 동시에 바꿨기 때문에 설정별 단독 기여도는 측정하지 않았다.



학습
Colab G4 · RTX PRO 6000 96GB · BF16



추론
로컬 GPU에서 제출용 예측 생성



기록
WandB 팀 프로젝트에 설정·지표·로그 공유



체크포인트
Best Accuracy / Best Loss 각각 저장

접근 ④ 촬영 환경을 닮은 증강, 누수 없는 검증



증강 6종 · 원본당 최대 9개 변형 · 증강을 겹쳐 적용하지 않음
증강 결과 60,338개 파일 (약 11.55GB)

샘플링

- 매 epoch 원본당 이미지 1장(view)만 선택
- 증강 70% / 원본 30% (기본), 80% / 20% (후보)
- 2 epoch 중 증강을 1회 이상 볼 확률 91% / 96%

누수 방지: 먼저 나누고, Train만 증강

원본 train
6,714장

Train 90% · 증강 적용

Validation 10% · 원본만

Dev 활용

3표 합의 2,026문항만 pseudo-label 후보로 분리. 증강 종류별 CSV를 나눠 Ablation 준비

3일 일정: 탐색 → 확장 → 개선

DAY 1 · 탐색

- 역할 분담, smoke test로 코드 동작 확인
- 7B vs 8B 소규모 비교
- 프롬프트 개선 (OCR 페르소나·단계 분석)
- 해상도 확대 · BF16 비양자화 결정
- 학습은 Colab, 추론은 로컬로 분리

산출 · 변경 프롬프트 채택, 27B 확장 준비

DAY 2 · 확장

- WandB 전면 도입, 팀원 초대
- 로컬 추론 결과 제출 (Kaggle 0.95204)
- 27B 최초 fine-tuning (Colab G4)
- 결과가 오히려 하락 → 과적합 의심
- 바닐라 모델과 동일 조건 비교

발견 · 최초 27B의 과적합 신호

DAY 3 · 개선

- 개선 설정으로 27B 재학습
- 증강 70% vs 80% 비교
- 심판 LLM 앙상블 설계·검토
- 후보 설정으로 전체 데이터 재학습
- 검증·Kaggle 결과 대조

결과 · 팀 최고 Kaggle 0.95918

시행착오: 세 번 멈추고 방향을 바꿨다

① 오래 학습할수록 나빠졌다

문제

최초 27B에서 epoch가 늘수록 검증 손실이 커짐

판단

학습 데이터에 과적합

조치

학습률 1e-4→2e-5, 최대 epoch 5→2, batch 확대

② 검증↑가 제출↑로 이어지지 않았다

문제

증강 데이터 일부를 학습한 모델로 검증(정확도) 향상 확인
→ BUT KAGGLE 제출 점수 하락

판단

검증에서 향상되었다는 +2문항 정도는 노이즈 수준의 차이

조치

오답 유형 분석 및 실험 재설계

③ 답만 합치는 앙상블

문제

제출 CSV 3개를 심판 LLM으로 조합하는 방식 설계

판단

정답 레이블이 없어 조합 효과를 검증할 수 없음

조치

CSV 조합 미채택 → 체크포인트 직접 추론 앙상블 검토

결과 ① 선택 단계: 방향은 잡았지만 차이는 작았다

모델 비교 · 약 1,700장 · 2 epoch

검증

Qwen2.5-7B

88.39%

손실 0.1240

Qwen3-8B

86.31%

손실 0.1457

+2.08%p ≈ 검증 약 170장 중 3~4문항 → 우열 확정 보류

프롬프트 비교 · 7B · 약 1,000장

검증

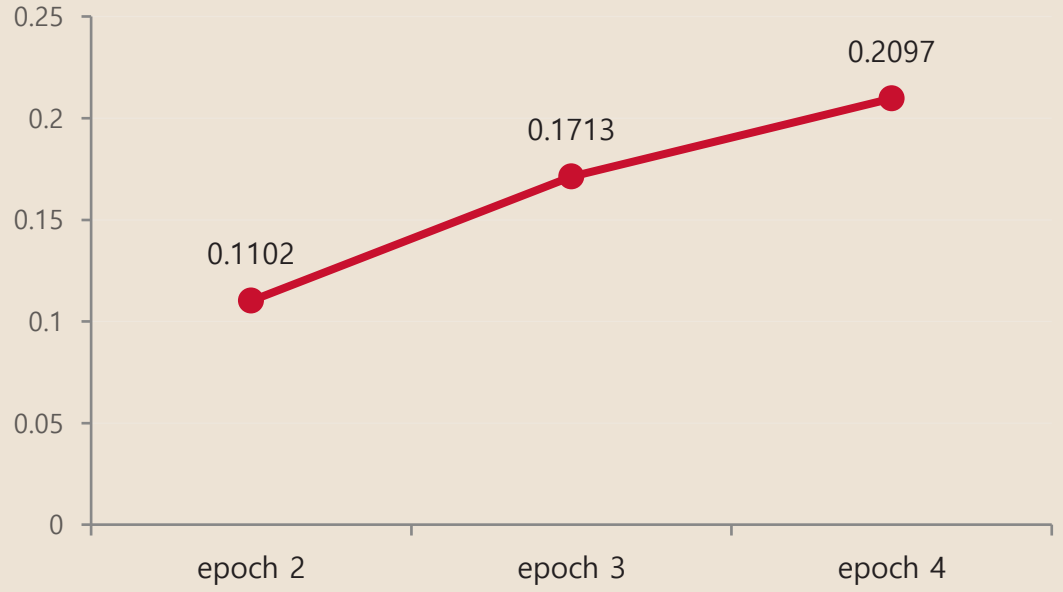
84% → 86%

Loss 0.1309 → 0.1151

두 지표 모두 개선 → 채택 (100문항 중 2문항 차이)

최초 27B · 검증 손실

검증



최고 검증 정확도 88.24% (epoch 3)
epoch 2→3 손실 +55% → 과적합 신호

결과 ② 최고 0.95918, 검증 상승 ≠ 제출 상승

Kaggle

0.95918

팀 최고 Kaggle 점수

개선 27B · 증강 70% · epoch 2

실험	검증 정확도	검증 손실	Kaggle
증강 70% · epoch 1	94.81%	0.0486	—
증강 70% · epoch 2	**95.11%**	0.0534	**0.95918**
증강 80% · epoch 1 (후보)	94.96%	0.0483	—
증강 80% · epoch 2 (후보)	95.41%	0.0541	**0.95918**
전체 6,714장 재학습	검증 없음	—	**0.95829**

+2문항의 착시

80% 후보의 검증 +0.30%p는 675문항 중 2문항. 제출 점수는 동일

같은 점수, 다른 답

후보 예측은 기존 제출과 48개(0.71%) · 58개(0.86%) 답이 다름

재학습 −0.00089

검증셋 제거·LoRA 재초기화·샘플 순서가 동시에 바뀌어 원인 단정 불가

다음 시도 ① 약점을 겨냥한 추가 데이터

9,535

추가 이미지

8,292

대표 문항

폴더 간 중복 미제거 수치.
대표 CSV와 전체 문항 CSV는 겹치므로 단순 합산하지 않음

폴더	이미지	문항	출처	겨냥	주의
count_color	2,000	2,000	CLEVR (합성)	**개수·색상**	실사 아님, 도메인 차이
english	3,000	3,000	ST-VQA	**영어 장면 텍스트**	non_english와 이미지 중복 가능
chinese	1,000	1,000	RCTW-17	**한자 간판**	정답이 자동 OCR 결과
japanese	745	1,025	JaWildText	**일본어 텍스트**	질문 자동 번역, 원래 평가셋
non_english	2,790	1,267	COCO-Text · ST-VQA	**다국어 텍스트**	1,901장은 문답 없음

EDA 기준 test의 약 70%가 OCR 질문, 색상 5.4%·수량 0.8% → 텍스트 데이터 비율을 색상·개수 데이터 비율보다 더 높게

정리

1. 고해상도 입력 · 27B LoRA · 증강으로
   팀 최고 Kaggle 0.95918

2. 검증 점수와 제출 점수를
   구분해 판단하는 기준을 세움

3. 다음은 약점을 겨냥한
   추가 데이터 학습

THANK YOU

Q&A

파이브가이즈